Audit méthodologique final

BIRD - prédiction de la prochaine œuvre par graphe spatio-temporel et apprentissage contrastif
Cahier de réalisation ordonné, version 1.1 - revue des méthodes contrastives au 23 septembre 2026

Décisions de périmètre. L'unité prédite est la prochaine œuvre observée (POI). Les deux données canoniques sont trajectories_poi.json et artworks_semantics.json. Le graphe exploite les sujets principaux et secondaires, la localisation et les transitions/temps. Descriptions et styles restent conservés pour un module PLM de prédiction de masque ultérieur ; ils ne contribuent ni aux entrées ni aux arêtes du présent modèle.

1. Portée et niveau de preuve

Cet audit spécifie les travaux à réaliser et les conditions de validation ; il ne présente aucun gain de performance comme acquis. Le passage salle → œuvre modifie à la fois le nombre de classes, les séquences et les baselines : les scores Rooms ne constituent donc pas une comparaison expérimentale directe. Le cadre est rétrospectif et transductif pour les identités/annotations d'œuvres ; les interactions des visiteurs de validation et de test doivent rester hors du graphe comportemental.

Constats vérifiés sur les quatre pièces jointes

Constat	Mesure / réserve
Journaux bruts BIRD	51 fichiers de débuts et 51 fichiers de fins ; 7 204 lignes de début et 5 635 lignes de fin. La différence brute de 1 569 n'est pas encore un décompte d'appariements ratés.
Catalogue et enrichissement	359 IDs distincts dans le catalogue et 359 dans le CSV sémantique ; ensembles d'IDs identiques ; 356 IDs différents parmi les débuts d'observation.
Qualité des sujets	2 sujets principaux « NA », 345 champs secondaires non vides ; 140 indicateurs desaccord_sujet=True. À examiner comme indice de révision, non comme erreur certaine.
Traçabilité de l'image	bilan.json : 359 « ok » ; 282 contrôles « retenu_par_IA_non_verifie_humain » et 77 « association_par_id_fournie_par_utilisateur ». « ok » ne vaut pas confirmation scientifique manuelle.
Ancien modèle Rooms	data.py sépare les visiteurs et bâtit le graphe à partir du train ; run.py calcule loss = supervised + contrastive(...). La documentation mentionne un coefficient de 0,05 : l'écart doit être résolu.

Sources internes : GSITM_CLL_Rooms(8).zip (data/BIRD, data.py, model.py, run.py, README.md), oeuvres_semantique(3).csv, bilan.json et resultats.zip. Les comptages sont des constats directs ; les interprétations et recommandations ci-dessous sont des décisions proposées.

2. Définition formelle de la tâche

Une visite est une suite ordonnée $E_v = (e_1, \ldots, e_n)$ d'observations d'œuvres, y compris deux occurrences distinctes de la même œuvre. À l'instant du début de l'observation courante t, prédire p_{t+1} à partir du préfixe $e_{1:t}$ observable à cet instant. La cible est l'ID de l'œuvre du début d'observation suivant ; ni la salle ni une œuvre voisine déduite de la carte. L'ensemble candidat exclut uniquement les œuvres dont l'indisponibilité est documentée sans ambiguïté à la date de visite.

Le choix du temps de prédiction « début courant » rend comparable chaque exemple, même sans fin d'observation : on peut utiliser les délais entre débuts déjà connus et les durées antérieures terminées, jamais la fin de l'observation courante ni le début suivant. Les variantes « prédiction à la fin courante » seraient une

autre tâche et seront étiquetées séparément.

3. Plan d’exécution : tâches et portes de validation

Ordre	Action à exécuter	Livrable / critère de passage
01	Geler sources, code, hachages, schémas, seed et définition de la tâche. Noter versions des annotations et contexte rétrospectif.	manifest.json ; règle du temps de prédiction écrite.
02	Auditer 51 couples de fichiers bruts, horloges, IDs, répétitions, entrées aberrantes, catalogue et dates de disponibilité.	audit_raw.json/csv ; chaque anomalie quantifiée, exemples traçables.
03	Apparier starts/ends au sein de chaque visite et œuvre, dans l’ordre, sans réutiliser une fin ; résoudre les chevauchements et ambiguïtés.	pairs_audit.csv ; 1 start → 0/1 end ; durée positive ; aucune fin réutilisée.
04	Appliquer l’imputation spécifiée en §4 ; conserver originaux, drapeaux et politique de causalité ; analyser biais selon salle/sujet/visite.	trajectories_poi.json et audit d’imputation ; tests pour premier/dernier événement.
05	Préparer les sujets, vérifier identité et désaccords d’annotation, joindre le catalogue ; exclure texte/style des features.	artworks_semantics.json ; vocabulaire contrôlé, provenance et cas à vérifier.
06	Figer split par visiteur avant toute statistique comportementale, normalisation ou réglage.	split.json ; groupes disjoints, même split pour toutes les variantes.
07	Construire graphes train uniquement, features temporelles causales et exemples de préfixes.	graph_manifest.json ; tests anti-fuite et candidat temporel.
08	Implémenter baselines, modèle POI, vues contrastives, objectif explicite et configurations.	runs réexécutables ; tests d’unité et test de surapprentissage d’un minilot.
09	Sélectionner sur validation, évaluer une fois sur test ; ablations, intervalles groupés et erreurs.	tableaux de résultats, scripts, checkpoints, article et limites.

4. Construction des trajectoires : appariement puis durée

4.1 Appariement avant estimation

Pour chaque visite : parser les deux flux, trier par timestamp en conservant l’ordre source en cas d’égalité, associer chaque fin à un début antérieur de même paintingId sans réutilisation. En présence de visites répétées d’une œuvre, l’appariement doit être déterministe et audité (p. ex. file FIFO par ID, puis contrôle des intervalles). Une fin antérieure au début, deux fins plausibles, des chevauchements incohérents, ou une observation finale sans fin doivent porter un statut explicite. La différence 7 204 − 5 635 n’est pas suffisante pour déduire exactement le nombre de fins manquantes.

4.2 Règle d’imputation demandée et bornes

Interprétation opérationnelle de la formule proposée : pour un événement i sans fin, ayant un début suivant i+1, poser $\Delta_i = \text{start}_{i+1} - \text{start}_i$, m_v = moyenne des (end − start) des paires fiables de la visite, puis :

$$\mathbf{d^*_i = (\Delta_i + m_v) / 2 \; ; \quad end^*_i = start_i + \min(\Delta_i, d^*_i).}$$

Cette moyenne des deux quantités correspond à « différence des débuts consécutifs + durée moyenne, divisée par deux ». La borne Δ empêche de terminer après le début suivant ; toutes les valeurs égales à Δ, non positives ou extrêmes sont signalées et analysées. Aucun début suivant pour le dernier événement : fin laissée inconnue ; si aucune paire fiable n’existe pour la visite : fin inconnue et indicateur « mean_unavailable », sans moyenne fabriquée. Le plafond et le traitement de l’égalité doivent être fixés dans la configuration avant entraînement.

Contrainte de causalité. La moyenne sur toute la visite peut contenir des fins futures ; le début suivant n'est connu qu'après la décision de prédire cet événement. Conserver cette estimation dans le JSON comme reconstitution rétrospective avec duration_origin = imputed_offline, mais ne jamais l'utiliser comme entrée au pas concerné. Pour une durée antérieure manquante, ne calculer la version exploitable qu'une fois le début suivant connu, avec la moyenne des fins fiables déjà observées dans le préfixe. Si elle n'existe pas : valeur masquée. Cette règle conserve l'imputation voulue sans fuite vers validation/test.

Analyse obligatoire : distribution des durées mesurées et imputées, part plafonnée, erreurs du pseudo-masquage (masquer artificiellement des fins connues), et ablation « temps mesuré seulement » / « temps mesuré + imputation causale ». Les durées imputées ne sont jamais présentées comme mesures réelles.

5. Schémas et contrôles des deux JSON

5.1 trajectories_poi.json

Un objet par visiteur avec ID stable, date/calendrier si reconstruite (et hypothèse de reconstruction), source start/end ; événements ordonnés avec event_index, poi_id, room_id, t_start, t_end_observed ou null, t_end_imputed_offline ou null, duration_observed ou null, duration_imputed_offline ou null, duration_origin, pair_status, t_start_next pour audit interne et disponibilité de chaque champ au temps de prédiction. Les timestamps et unités sont explicités. Les features de modèle sont produites par une fonction de préfixe distincte qui ne lit pas t_start_next ou les statistiques de fin de visite pour l'exemple courant.

Contrôles : IDs valides dans le catalogue, ordre non décroissant puis gestion des égalités, temps finis et positifs, end ≥ start pour les paires acceptées, aucun événement silencieusement perdu, aucune fusion des répétitions consécutives, anomalies inscrites dans le rapport. Le référentiel Rooms ne sert jamais de source d'événements POI car il agrège des observations.

5.2 artworks_semantics.json

Un objet par image_id avec room_id et coordonnées/localisation documentées si disponibles ; hook/unhook en champs datés avec qualité connue/inconnue ; subject_main normalisé, subject_secondary liste unique normalisée sans répliquer le sujet principal ; annotations brutes et provenance/version/indicateur de revue. Conserver titre, artiste, description et style dans des champs archivés, marqués reserved_for_PLM ; aucun encodeur, nœud, arête ou feature du STKG actuel ne les lit.

Les 2 sujets principaux NA restent « unknown » et ne créent pas une catégorie savante artificielle. Il faut vérifier manuellement un échantillon stratifié (désaccord, sans revue humaine, sujet rare, NA) avec deux annotateurs si possible et publier l'accord inter-annotateurs ou au minimum les taux de désaccord et les règles d'arbitrage. La présence de « ok » dans le bilan ne suffit pas à valider la vérité des sujets.

6. STKG, temporalité et modèle contrastif

6.1 Graphe hétérogène minimal

Nœuds / arêtes	Origine et règle
Artwork → Room	Catalogue statique ; localisation valable pour la période de visite, contrôle si changement daté.
Artwork → Subject (main)	Sémantique normalisée ; type d'arête spécifique, une principale ou statut unknown.
Artwork → Subject (secondary)	0..n secondaires ; relation distincte de la principale ; pas d'arête à partir du texte/style.
Artwork → Artwork (transition)	Comptages orientés sur seules visites train, événements POI consécutifs ; lissage/boucles déclarés.
Temps sur transition	Statistiques de délais et durées dérivées du train et seulement de valeurs permises ; normalisation calculée sur train.

Ce STKG représente la localisation, les sujets et les transitions temporalisées ; il ne prétend pas que les annotations statiques fournissent à elles seules une dynamique temporelle. Si les nœuds POI sont connus pour test mais sans transitions de test, déclarer clairement le protocole transductif. Mesurer le taux de POI cibles absents du train, et séparer performance sur cibles vues/non vues quand possible.

6.2 Architecture, pertes et représentations

Encoder les relations par paramètres distincts (attention relationnelle ou agrégation par relation), puis concaténer/projeter les features temporelles du préfixe dans un GRU de taille contrôlée. Produire z_p pour chaque œuvre candidate et h_t pour la visite ; score(p) = $h_t^T W z_p + b_p$ optionnel ablaté. Cette sortie force la représentation du candidat à intervenir. Masquer les candidats temporellement indisponibles quand la date est fiable ; enregistrer l'effet exact de ce masque et appliquer la même règle à toutes les baselines.

Le code Rooms existant doit être porté avec une comparaison de sorties/unités, pas copié aveuglément : le run.py additionne effectivement les deux termes à λ = 1 tandis que README.md indique 0,05. La fonction contrastive du model.py forme une matrice B × B entre deux passes à dropout et calcule deux entropies croisées ; c'est une InfoNCE bidirectionnelle, sans les 2B représentations et les négatifs intra-vue de la NT-Xent SimCLR canonique. Elle masque les historiques strictement identiques, mais aucune autre collision de cible. Ne pas la qualifier de « NT-Xent de SimCLR » sans modifier sa définition. Fournir un tableau « valeur effective du code / valeur publiée / valeur retenue ».

6.3 Spécification contrastive avant implémentation

Variante principale, sobre et vérifiable : deux passages indépendants du même préfixe causal dans le même encodeur, dropout des représentations et, uniquement si contrôlé, faible dropout des arêtes de transition issues du train ; toujours préserver l'ordre des œuvres, l'œuvre courante, les nœuds d'œuvre et la relation sujet principal. Une petite tête de projection MLP normalise les vecteurs uniquement pour la perte contrastive ; les vecteurs avant cette tête servent à prédire. Fixer le générateur, la probabilité de dropout et le même jeu d'exemples pour tous les bras expérimentaux.

Objectif : retenir soit InfoNCE bidirectionnelle B × B et la nommer ainsi, soit NT-Xent standard sur 2B vues ; écrire le dénominateur, les exclusions et la température τ dans la méthode. Deux vues d'un même préfixe forment un positif. Masquer au minimum les copies du même préfixe et tester le masquage des exemples partageant la même prochaine œuvre (risque de faux négatifs) ; rapporter le nombre moyen de négatifs effectifs et ignorer les ancres qui n'en ont aucun. Ne pas supposer qu'un sujet commun rend deux œuvres identiques : le masquage selon les sujets est une expérience distincte, non une règle implicite. L = CE(next POI) + λ L_{CL} ; journaliser séparément les deux pertes et les normes des gradients.

Attribution au graphe : deux vues du même préfixe consommant des embeddings de graphe constituent du contraste au niveau des séquences, pas automatiquement un contraste du graphe lui-même. Si l'article revendique « graph contrastive learning », ajouter et ablater un alignement d'une même œuvre entre vue comportementale (transitions train) et vue statique (salle et sujets), avec deux projecteurs et négatifs définis, ou employer un nom plus exact : « apprentissage contrastif de trajectoires conditionné par STKG ». Pour une œuvre absente des transitions train, expliciter le repli sémantique ; vérifier qu'un embedding d'ID partagé ne rend pas l'alignement trivial.

Contrôle obligatoire : supervision seule ; augmentation + supervision sans L_{CL} ; même augmentation + L_{CL} ; tête de projection absente/présente ; vues uniquement dropout vs dropout d'arêtes ; λ=0 et λ>0. Sur 51 visites, choisir les probabilités et dimensions par validation, sans considérer une architecture plus grande comme supérieure par principe.

7. Protocole expérimental préenregistré

7.1 Séparation, réglage, métriques

Split visiteur fixe (p. ex. 35/8/8 comme Rooms si les 51 visites sont admissibles après audit) ; traiter visiteur et non ligne comme unité indépendante. Figer liste/seed avant tuning. Toute fréquence POI, arête, durée moyenne globale, standardisation, biais et paramètre sont appris sur le train. Choix d'architecture, de λ, de τ, d'arrêt et de masque uniquement sur validation. Test utilisé pour le bilan final après gel du protocole. Conserver aussi un protocole de splits groupés répétés pour la robustesse, en séparant nettement son rôle du test final.

Publier N visiteurs, N préfixes, N cibles, taux de cibles vues, Accuracy@1, Hit@5/10, MRR en micro et moyenne macro par visiteur. Calculer les intervalles et différences appariées en rééchantillonnant les visiteurs entiers, jamais les transitions isolées ; préciser le nombre de visiteurs test (8 pour un split 35/8/8) et la largeur des intervalles. Plusieurs seeds d'initialisation sur split gelé ; la variabilité des splits reste un autre axe. Ne pas confondre plafond empirique d'un modèle donné et borne théorique du jeu.

7.2 Comparaisons et ablations, à exemples identiques

Bloc	Modèles / question isolée
B0 - baselines	Popularité train, Markov-1/2, GRU POI-ID, SASRec POI-ID et une variante temporelle (p. ex. TiSASRec) si sa mise en œuvre est comparable ; mêmes exemples, candidats, histoire et réglage validation.
B1 - structure	Graphe POI transitions seul ; puis + Room ; puis + sujet principal ; puis + sujets secondaires. Mesurer aussi un contrôle de sujets permutés entre œuvres (même distribution).
B2 - temps	B1 + délais entre débuts connus ; + durées observées du préfixe ; + durées imputées causalement ; version sans composante temporelle.
B3 - contrastif	Même graphe/encodeur/supervision : sans augmentation ; augmentation sans contraste ; + contraste de séquences ; éventuellement + contraste entre vues du graphe. λ/τ et poids de chaque perte réglés sur validation.
B4 - sensibilité	Évaluation appariement seulement, observations à fin manquante conservées, masque de disponibilité actif/inactif, sujets après vérification, longueurs d'historique.

Ne pas utiliser description, style ou PLM dans ces lignes ; ces signaux sont réservés à un travail ultérieur. Pour comparer les variantes, maintenir les mêmes cibles et la même population primaire ; les jeux paired-only et autres exclusions sont rapportés comme études de sensibilité avec leurs dénominateurs propres. Un article WWW 2024 trouve que certaines augmentations séquentielles rivalisent avec des méthodes contrastives : isoler leur apport est indispensable ; ce résultat externe ne préjuge pas de BIRD.

8. Tests de conformité et critères de clôture

• Test « futur » : modifier des événements de validation/test et vérifier que graphe, normalisation et statistiques train ne bougent pas ; modifier la suite future d'une visite et vérifier que les features d'un préfixe restent identiques.

• Test des deux JSON : cardinalités, clés uniques, compatibilité IDs, schéma, dates et provenance ; audit de 100 % des fins isolées/ambiguës, et revue humaine ciblée des annotations à risque.

• Test du masque : à chaque préfixe, la cible observée ne doit jamais être exclue ; tout conflit entre date du catalogue et observation réelle est journalisé et résolu avant métriques.

• Test d'entraînement : gradation supervisée/contrastive non nulle, deux vues indépendantes mais cohérentes, poids λ effectif journalisé, reproductibilité au seed près, surapprentissage contrôlé d'un très petit échantillon.

• Clôture : manifestes et hashes, scripts source → JSON → graphe → métriques, configurations/versions, tables par ablation, intervalles, limites des 51 visites et des étiquettes générées par IA, et absence d'affirmation de gain sans comparaison contrôlée.

Critère de publication. La contribution démontrable n'est pas « embeddings plus riches donc meilleure précision », mais un effet mesuré, reproductible et attribuable de chaque information ajoutée sur la prédiction POI, avec incertitude par visiteur et contrôle des fuites.

9. Positionnement face aux méthodes publiées

La notion de « standard actuel » concerne surtout la définition vérifiable des vues, le contrôle des négatifs et une comparaison équitable. Un GRU compact reste une hypothèse raisonnable pour BIRD ; le choix final entre GRU et attention doit découler des résultats sur les mêmes exemples. Aucune performance publiée sur de grands jeux de check-in ne s'applique automatiquement aux visites du musée.

Travail	Leçon pour BIRD / décision de protocole
SimCLR, ICML 2020	La construction des vues et une tête de projection sont des éléments empiriquement importants ; nommer précisément la loss plutôt qu'utiliser NT-Xent comme terme générique.
HestGCL, 2025	Les vues spatiales et temporelles et leur contraste sont une piste POI pertinente. Notre dropout de séquence seul n'autorise pas à revendiquer une contribution contrastive au niveau des relations du STKG.
STKG-PLM, IEEE TKDE 2025	Une méthode publiée associe graphe spatio-temporel contrastif et modèle de langue à prompts. Notre présente expérience teste uniquement sujets, localisation et temps ; PLM, style et description appartiennent à une étape séparée.
Zhou et al., WWW 2024	Certaines augmentations sans loss contrastive rivalisent avec des modèles contrastifs ; inclure le bras « augmentation sans contraste » pour mesurer la valeur propre de L_CL.
SASRec / TiSASRec	Ces encodeurs séquentiels et temporels fournissent des comparateurs pertinents au GRU ; garder une capacité et un budget de réglage comparables sur les 51 visites.

10. Sources et traçabilité

Pièces auditées : GSITM_CLL_Rooms(8).zip : data/BIRD/start_obs_artworks/*.csv ; end_obs_artworks/*.csv ; artworks_dataset.csv ; data.py ; model.py ; run.py ; README.md. oeuvres_semantique(3).csv ; bilan.json ; resultats.zip. Les valeurs et limites d'identité ont été calculées/relues sur ces pièces.

Références externes : Worm et al., « BIRD », DOI 10.1145/3708319.3733686, https://dl.acm.org/doi/10.1145/3708319.3733686 ; projet BIRD, https://mbanv2.loria.fr/ ; Chen et al. (2020), « A Simple Framework for Contrastive Learning of Visual Representations », https://proceedings.mlr.press/v119/chen20j.html ; Liu et al. (2025), « Heterogeneous Spatio-Temporal Graph Contrastive Learning for Point-of-Interest Recommendation », https://www.sciopen.com/article/10.26599/TST.2023.9010148 ; Chen et al. (IEEE TKDE 2025), « Next-POI Recommendation via Spatial-Temporal Knowledge Graph Contrastive Learning and Trajectory Prompt », https://ieeexplore.ieee.org/document/10904285 ; Zhou et al. (WWW 2024), « Is Contrastive Learning Necessary? A Study of Data Augmentation vs Contrastive Learning in Sequential Recommendation », https://arxiv.org/abs/2403.11136 ; Kang et McAuley (2018), « SASRec », https://arxiv.org/abs/1808.09781 ; Li et al. (2020), « TiSASRec », https://dl.acm.org/doi/10.1145/3336191.3371786 ; scikit-learn, GroupShuffleSplit, https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GroupShuffleSplit.html ; Deen & de Rooij, « ClusterBootstrap », https://pmc.ncbi.nlm.nih.gov/articles/PMC7148287/. Ces références établissent les pratiques comparées, sans transposer leurs gains chiffrés à BIRD.